基于矩阵分解的图书馆书籍推荐系统

AIC-2025 复赛参赛方案

凳子齐队　凌子润

2025 年 11 月

摘要

本文介绍了我们参加 AIC-2025（人工智能竞赛）复赛的完整方案。赛题任务为**图书馆书籍推荐**：根据用户的历史借阅记录，预测其下一次最可能借阅的图书。我们设计了两套基于矩阵分解的推荐模型——标准矩阵分解（MF）和融合内容信息的混合矩阵分解（CBMF），并采用了一系列数据预处理、特征工程和后处理策略。最终方案在 F1 评价指标上取得了有效成绩。本文将从赛题分析、数据处理、模型设计、训练策略和代码工程五个方面进行详细阐述。

目录

1 赛题背景与任务分析 **3**
- 1.1 赛题概述 . . . 3
- 1.2 评价指标 . . . 3
- 1.3 核心挑战 . . . 3

2 数据探索与预处理 **3**
- 2.1 数据概况 . . . 3
- 2.2 隐式反馈转显式评分 . . . 4
- 2.3 图书向量生成 . . . 4
- 2.4 用户-物品矩阵构建 . . . 4

3 模型设计 **5**
- 3.1 模型一：标准矩阵分解（MF） . . . 5
  - 3.1.1 模型结构 . . . 5
  - 3.1.2 训练配置 . . . 6
- 3.2 模型二：内容增强矩阵分解（CBMF） . . . 6
  - 3.2.1 核心思想 . . . 6

3.2.2 模型结构 6
3.2.3 训练配置 8
3.3 模型对比 8

4 训练与优化策略 **8**
4.1 数据划分：Leave-last-N-out 8
4.2 后处理：随机搜索优化 8

5 系统架构与代码工程 **9**
5.1 项目结构 9
5.2 设计模式：模板方法模式 9
5.3 v1 到 v2 的重构改进 10
5.4 端到端流水线 10

6 实验结果与经验总结 **10**
6.1 模型迭代历程 10
6.2 关键经验 11

7 总结与展望 **11**

1 赛题背景与任务分析

1.1 赛题概述

AIC-2025 是一项面向高校学生的人工智能竞赛，本次复赛的核心任务是**图书馆书籍推荐**。给定用户的历史借阅数据和图书元数据，参赛者需要为每位用户预测其最可能借阅的图书列表。

1.2 评价指标

赛题采用 **F1 Score** 作为主要评价指标，综合考虑精确率（Precision）和召回率（Recall）：

$$\text{Precision} = \frac{|\text{预测借阅} \cap \text{实际借阅}|}{|\text{预测借阅}|} \tag{1}$$

$$\text{Recall} = \frac{|\text{预测借阅} \cap \text{实际借阅}|}{|\text{实际借阅}|} \tag{2}$$

$$\text{F1} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{3}$$

提交结果的 F1 分数需大于 0.0055 方为有效提交。

1.3 核心挑战

- **稀疏性**：用户-图书交互矩阵极度稀疏，大部分用户仅借阅少量图书；
- **隐式反馈**：借阅行为本身是隐式信号，需要转化为显式评分；
- **冷启动**：部分用户或图书的交互记录极少；
- **数据噪声**：存在未归还图书、异常借阅时长等情况。

2 数据探索与预处理

2.1 数据概况

原始数据包含三张核心表格：

表 1: 原始数据集概览

文件	说明	关键字段
`user.csv`	用户信息	user_id, 用户属性
`item.csv`	图书信息	book_id, 书名, 作者等
`inter_reevaluation.csv`	借阅记录	user_id, book_id, 借阅/归还时间, 续借次数

2.2 隐式反馈转显式评分

原始数据仅包含借阅行为（隐式反馈），我们设计了一套评分公式将其转化为 $[1, 10]$ 的显式评分：

$$\text{score} = 0.8 \times \widehat{\text{duration}} + 0.2 \times \widehat{\text{renewals}} \tag{4}$$

$$\text{rating} = \text{score} \times 9 + 1 \tag{5}$$

其中 $\widehat{\text{duration}}$ 为归一化的借阅时长，$\widehat{\text{renewals}}$ 为归一化的续借次数。

设计直觉：借阅时长越长、续借次数越多，说明用户对该书的兴趣越强烈。对于未归还的图书，我们使用固定参考日期（2025-11-02）计算借阅时长，确保结果的确定性。

2.3 图书向量生成

为了在推荐模型中融入图书的内容信息，我们使用 **BAAI/bge-small-zh** 句向量模型将图书的文本元数据（书名、作者、简介等）编码为 512 维的稠密向量：

$$\mathbf{v}_{\text{book}} = \text{BERT}_{\text{bge-small-zh}}(\text{text_metadata}) \in \mathbb{R}^{512} \tag{6}$$

该预训练模型基于 BERT 架构，具有 4 层 Transformer、8 个注意力头，词表大小为 21128，专为中文文本设计。

2.4 用户-物品矩阵构建

将所有借阅记录汇总为用户-物品评分矩阵 $\mathbf{R} \in \mathbb{R}^{M \times N}$，其中 M 为用户数，N 为图书数。同时建立双向 ID 映射：

Listing 1: ID 映射结构

```
{
    "user_to_index": {"U001": 0, "U002": 1, ...},
    "index_to_user": {"0": "U001", "1": "U002", ...},
    "item_to_index": {"B001": 0, "B002": 1, ...},
```

```
    "index_to_item": {"0": "B001", "1": "B002", ...}
}
```

3 模型设计

我们设计了两套推荐模型：标准矩阵分解（MF）和融合内容信息的混合矩阵分解（CBMF）。

3.1 模型一：标准矩阵分解（MF）

3.1.1 模型结构

标准 MF 模型的核心思想是将用户和物品分别映射到低维隐空间：

$$\hat{r}_{ui} = \mathbf{p}_u^\top \mathbf{q}_i + b_u + b_i + \mu \tag{7}$$

其中 $\mathbf{p}_u \in \mathbb{R}^k$ 为用户隐向量，$\mathbf{q}_i \in \mathbb{R}^k$ 为物品隐向量，b_u, b_i 为偏置项，μ 为全局均值。我们取隐因子维度 $k = 20$。

在此基础上，我们额外引入一个 MLP 评分头来增强模型的非线性表达能力：

$$\hat{r}_{ui}^{\text{final}} = \text{MLP}\left([\mathbf{p}_u \,\|\, \mathbf{q}_i \,\|\, \mathbf{p}_u^\top \mathbf{q}_i \,\|\, \cos(\mathbf{p}_u, \mathbf{q}_i)]\right) \tag{8}$$

其中 $\|$ 表示拼接操作，输入维度为 $20 + 20 + 1 + 1 = 42$。MLP 结构为：

Listing 2: MF 评分头结构

```
Linear(42, 8) -> ReLU -> Linear(8, 1)
```

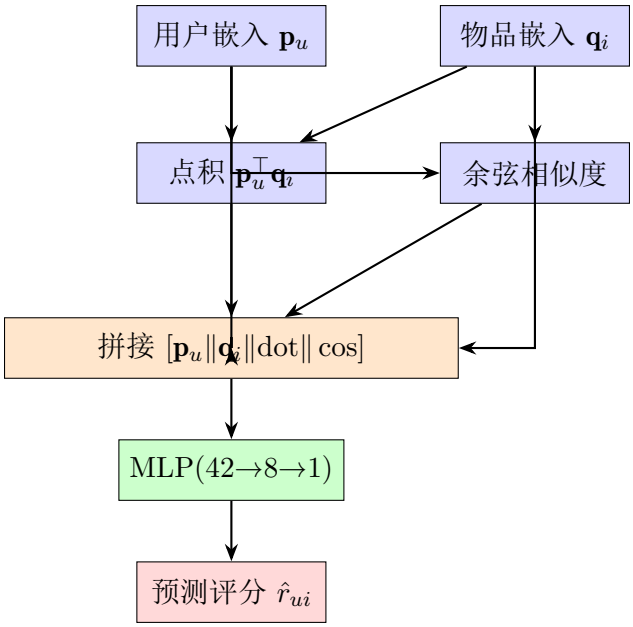


图 1: MF 模型结构示意图

3.1.2 训练配置

表 2: MF 模型训练超参数

参数	值
隐因子维度	20
训练轮数	250
批大小	2048
优化器	Adam (lr=2e-4, amsgrad=True)
学习率调度	ReduceLROnPlateau
损失函数	MSE
数据划分	Leave-last-2-out

3.2 模型二：内容增强矩阵分解（CBMF）

3.2.1 核心思想

标准 MF 仅利用用户-物品交互信息，忽略了物品本身的内容特征。CBMF 通过一个**内容映射网络**将图书的文本向量投影到隐空间，实现内容信息与协同过滤的融合。

3.2.2 模型结构

物品隐向量不再作为独立的嵌入参数，而是由内容向量通过映射网络生成：

$$\mathbf{q}_i = f_\theta(\mathbf{v}_i^{\text{content}}) \tag{9}$$

其中映射网络 f_θ 的结构为：

Listing 3: CBMF 内容映射网络

```
Linear(512, 512) -> BatchNorm -> ReLU
Linear(512, 256) -> BatchNorm -> ReLU
Linear(256, 1024)
```

最终评分为：

$$\hat{r}_{ui} = \mathbf{p}_u \odot \mathbf{q}_i + b_u + b_i \tag{10}$$

其中 $\odot$ 表示逐元素乘积（Hadamard 积），用户隐向量维度为 $k = 1024$。

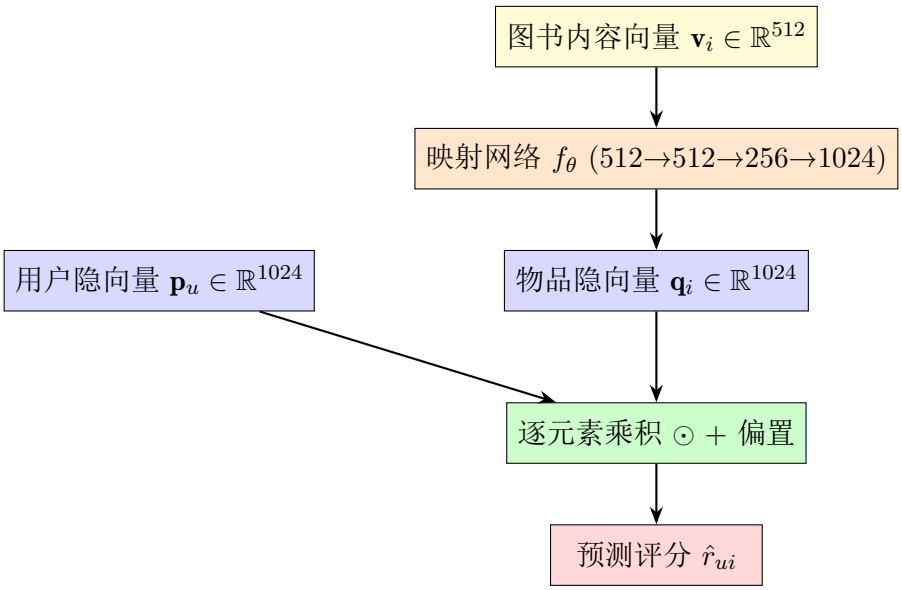


图 2: CBMF 模型结构示意图

3.2.3 训练配置

表 3: CBMF 模型训练超参数

参数	值
隐因子维度	1024
训练轮数	150
批大小	4096
优化器	Adam (lr=1e-2)
学习率调度	StepLR
早停	patience=3
损失函数	MSE
数据划分	Leave-last-2-out

3.3 模型对比

表 4: MF 与 CBMF 模型对比

特性	MF	CBMF
隐因子维度	20	1024
物品表示	独立嵌入参数	内容向量映射
内容信息	不利用	融合
评分方式	MLP 头	逐元素乘积
适用场景	交互数据充足	冷启动、内容丰富

4 训练与优化策略

4.1 数据划分：Leave-last-N-out

对每位用户，将其最近的 $N = 2$ 次借阅作为验证集，其余作为训练集。这种划分方式模拟了真实的预测场景——根据历史行为预测未来行为。

4.2 后处理：随机搜索优化

在模型生成初始推荐列表后，我们使用**贪心随机搜索**进一步优化 F1 分数：

1. 随机选择一个用户子集；

2. 对子集中的每位用户，随机替换其推荐列表中的一本书；

3. 计算新的 F1 分数，若提升则保留更改；

4. 重复最多 10,000 次迭代。

该策略本质上是一种局部搜索，通过微调推荐结果来逼近更高的 F1 分数。

5 系统架构与代码工程

5.1 项目结构

项目采用分层架构设计，从 v1 的单体脚本重构为 v2 的模块化结构：

Listing 4: 项目目录结构

```
book-rec/
|-- src/                        # 核心源码（v2）
|   |-- config/                 # 配置层：超参数、路径
|   |-- data/                   # 数据层：预处理、矩阵构建、数据集
|   |-- models/                 # 模型层：MF、CBMF 定义
|   |-- training/               # 训练层：训练循环、检查点
|   |-- evaluation/             # 评估层：推理、F1 计算、搜索优化
|   +-- utils/                  # 工具层：日志、IO、相似度计算
|-- cli/                        # 命令行入口
|   |-- preprocess.py           # Step 1: 评分计算 + 图书向量
|   |-- build_matrix.py         # Step 2: 用户-物品矩阵
|   |-- train.py                # Step 3: 模型训练
|   |-- inference.py            # Step 4: 推荐生成
|   +-- evaluate.py             # Step 5: F1 评估
|-- DataLoad/                   # 原始数据
|-- MyModule/                   # 预训练模型 (bge-small-zh)
|-- models/                     # 训练好的模型权重
|-- submissions/                # 提交文件
+-- legacy/                     # v1 旧代码（归档）
```

5.2 设计模式：模板方法模式

通过基类提取公共逻辑，子类只需实现差异部分：

Listing 5: 基类设计示例

```
class BaseRecommender(nn.Module):
```

```
    """推荐模型基类，定义通用接口"""
    def predict(self, user_ids, item_ids):
        raise NotImplementedError

class MatrixFactorization(BaseRecommender):
    """标准 MF 实现"""
    ...

class ContentBasedMF(BaseRecommender):
    """内容增强 MF 实现"""
    ...
```

5.3 v1 到 v2 的重构改进

表 5: v1 到 v2 的关键改进

类别	改进内容
架构	分层包结构，职责清晰
去重	基类提取公共逻辑，消除 MF/CBMF 间重复代码
健壮性	修复 ID 映射错误、off-by-one、硬编码路径
工具化	统一 CLI 入口，替代分散的 `__main__` 块
安全性	`weights_only=True` 加载检查点

5.4 端到端流水线

整个推荐系统的执行流程如下：

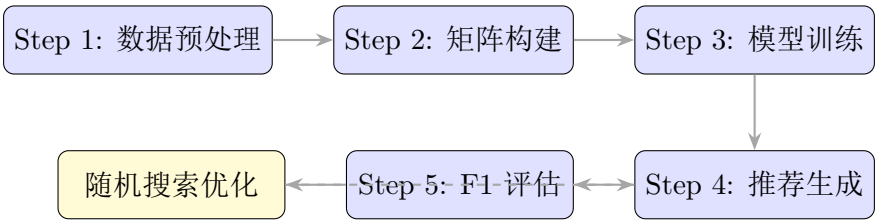


图 3: 推荐系统端到端流水线

6 实验结果与经验总结

6.1 模型迭代历程

在比赛期间，我们进行了大量实验，训练了多个模型变体：

表 6: 主要模型变体

模型	类型	说明
mf_100	MF	隐因子 100 维
mf_128	MF	隐因子 128 维
mf_256	MF	隐因子 256 维
mf_v2/v3	MF	迭代改进版本
mf_final	MF	最终 MF 版本
cb_mf_model	CBMF	内容增强版本
fin_model	MF	最终提交模型

6.2 关键经验

1. **评分公式设计至关重要**：将隐式反馈转化为合理的显式评分是整个系统的基础。借阅时长和续借次数的加权组合能有效反映用户兴趣强度。

2. **内容信息的融合**：CBMF 通过将图书文本向量映射到隐空间，有效缓解了冷启动问题。对于借阅记录较少的用户，内容信息提供了有价值的补充信号。

3. **后处理的价值**：随机搜索优化虽然简单，但在模型预测的基础上能带来可观的 F1 提升。推荐系统的最终效果往往取决于这些" 最后一公里" 的优化。

4. **代码工程的重要性**：从 v1 到 v2 的重构大幅提升了开发效率。清晰的模块划分使得实验迭代更加便捷，也减少了 bug 的引入。

7 总结与展望

本文介绍了我们在 AIC-2025 复赛中的书籍推荐方案。通过设计评分公式将隐式反馈转化为显式评分，构建了标准 MF 和内容增强 CBMF 两套模型，并采用随机搜索优化后处理策略。在工程方面，项目从单体脚本重构为分层模块化架构，显著提升了代码质量和开发效率。

未来改进方向：

- 引入序列模型（如 GRU4Rec、SASRec）捕捉用户的时序借阅模式；
- 利用图神经网络（GNN）建模用户-图书-作者等多关系图；
- 探索负采样策略的优化，提升隐式反馈下的训练效果；
- 集成多种模型的预测结果，通过 Stacking 进一步提升性能。

参考资料

1. Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.

2. He X, Liao L, Zhang H, et al. Neural collaborative filtering[C]//WWW, 2017: 173-182.

3. BAAI/bge-small-zh: https://huggingface.co/BAAI/bge-small-zh